

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«ВЯТСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ»
Институт математики и информационных систем
Факультет автоматики и вычислительной техники
Кафедра электронных вычислительных машин

Отчёт по лабораторной работе №5
по дисциплине
«Промпт-инжиниринг»
«Создание и редактирование аудиоконтента с помощью
промпт-инжиниринга»
«Вариант 4»

Выполнил студент гр. ИВТб-1303-06-00 _____/Гортоломей И.К./

Проверил доцент кафедры ЭВМ _____/Колупаев А.В./

Киров
2026

Введение

Цель работы: Формирование практических навыков построения конвейеров обработки аудиоданных с использованием свободных облачных сервисов и мультимодальных нейронных сетей. Освоение методов параметрической настройки генерации речи, составления текстурных промптов для аудио-сцен и применения контекстной инъекции для точного распознавания зашумлённой речи.

Языковые модели, используемые в работе:

- **Zvukogram** <https://zvukogram.com> – облачный сервис синтеза речи с параметрическим управлением (скорость, высота тона)
- **EzAudio** на Hugging Face Space – модель генерации звуковых эффектов по текстовому описанию
- **Qwen chat.qwen.ai**

Предметная область варианта 4: Игровая индустрия (Таверна)

- **Роль А (Торговец):** Весёлый, хриплый бас. Характер: громкий хохот, прочистка горла, энергичная речь.
- **Роль Б (Путник):** Недоверчивый, тихий голос. Характер: осторожность, сомнения, приглушённая речь.
- **Фоновая сцена:** Средневековая таверна: звон посуды, гул толпы, треск огня в камине.

1 Задание №1: Управляемая генерация речи по заданному тексту и параметрам

1.1 Постановка задачи варианта

Вариант №4: Игровая индустрия - Таверна Вам предстоит выступить в роли инженера по синтезу речи, создающего озвучку для диалога торговца и путника в таверне. Ваша задача — выбрать один из доступных онлайн-инструментов (Zvukogram, Voicebot или Parler-TTS) и сгенерировать аудио-файлы для каждой реплики диалога. Ключевое требование — голос не должен звучать монотонно: необходимо использовать доступные настройки сервиса, чтобы передать характер персонажа (веселье и хриплость торговца, недоверчивость и тихость путника).

1.2 Сценарий диалога (10 реплик)

(курсивом выделены сложные для распознавания сущности)

- **Торговец** (весело, с хриплым басом, прочищает горло):
— Эй, путник! Заходи, не стесняйся! У меня *эль «Золотой дракон»* лучший в округе!
- **Путник** (тихо, недоверчиво):
— Гм... Спасибо. А сколько стоит кружка? Не люблю, когда обманывают.
- **Торговец** (громко смеётся):
— Ха-ха-ха! Да ты не бойсь! *50 медных монет* за кружку. Честная цена!
- **Путник** (осторожно, тихо):
— Хм... А что за *таверна «Пьяный единорог»*? Странное название.
- **Торговец** (с гордостью, прочищает горло):
— О, это легендарное место! Сам *барон фон Штейнберг* у нас бывал! И *графиня Изольда де Монфор*!

- **Путник** (скептически):
— Правда? А почему тогда *курица «Феникс»* на гриле так дорого стоит? *75 серебряных?*
- **Торговец** (энергично):
— Да это же магическая птица! Говорят, возрождается каждые *три дня!* Стоит того!
- **Путник** (тихо, сомневаясь):
— Ладно... А промокод «*НОВИЧОК2026*» примете? Мне *маг Мерлинус* дал.
- **Торговец** (после паузы):
— Мерлинус, говоришь? Ну ладно, ладно... Скидка *15%* будет. Заказывай!
- **Путник** (немного расслабленнее):
— Хорошо. Тогда одну кружку эля и *кусоч пирога «Яблочный вихрь»*.

1.3 Настройки голосовых профилей в Zvukogram

Торговец:

- **Голос:** «Дмитрий» (мужской, низкий тембр)
- **Скорость:** +10% (энергичная, оживлённая речь)
- **Высота тона (Pitch):** -1st (хриплый бас, понижение для глубины)
- **Пунктуация:** восклицательные знаки! и многоточия... для передачи эмоций и смеха

Путник:

- **Голос:** «Антон» (мужской, мягкий тембр)
- **Скорость:** -10% (осторожная, медленная речь)

- **Высота тона (Pitch):** +1st (немного выше для передачи неуверенности)
- **Пунктуация:** многоточия... и вопросы? для передачи сомнений

1.4 Скриншоты настроек




Рис. 1: Настройки синтеза речи для роли Торговца




Рис. 2: Настройки синтеза речи для роли Путника

 реплика 1 - путник.mp3	09.05.2026 10:16	MP3 - Audio File	41,6 КБ
 реплика 1 - торговец.mp3	09.05.2026 10:10	MP3 - Audio File	40,3 КБ
 реплика 2 - путник.mp3	09.05.2026 10:17	MP3 - Audio File	34,3 КБ
 реплика 2 - торговец.mp3	09.05.2026 10:11	MP3 - Audio File	40,3 КБ
 реплика 3 - путник.mp3	09.05.2026 10:17	MP3 - Audio File	49,3 КБ
 реплика 3 - торговец.mp3	09.05.2026 10:13	MP3 - Audio File	45,0 КБ
 реплика 4 - путник.mp3	09.05.2026 10:18	MP3 - Audio File	50,4 КБ
 реплика 4 - торговец.mp3	09.05.2026 10:14	MP3 - Audio File	39,9 КБ
 реплика 5 - путник.mp3	09.05.2026 10:18	MP3 - Audio File	39,9 КБ
 реплика 5 - торговец.mp3	09.05.2026 10:15	MP3 - Audio File	43,7 КБ

Рис. 3: Экспортированные аудиофайлы реплик

Нейросеть не генерирует физиологические звуки (смех, прочистку горла) по умолчанию, но успешно передаёт их эмоциональную окраску через просодические параметры и пунктуацию. Баланс между «скоростью» и «высотой тона» позволил избежать роботизированного звучания.

2 Задание №2: Генерация аудио-сцены по заданным параметрам

2.1 Постановка задачи варианта

Вариант №4: Игровая индустрия - Таверна Фоновая аудио-сцена: Средневековая таверна — звон посуды и кружек, гул множества голосов, треск огня в камине, случайный смех, атмосфера оживлённого заведения.

2.2 Промпт для EzAudio

Большинство открытых моделей Text-to-Audio обучались на англоязычных датасетах, поэтому промпт составлен на английском с акцентом на физическую текстуру звука и атмосферу средневекового заведения:

- 1 Positive Prompt:
- 2 Medieval tavern ambience, crowded inn with multiple conversations, clinking of wooden mugs and ceramic plates, crackling fireplace, warm acoustic space, distant laughter, bustling atmosphere, high fidelity, authentic medieval soundscape

3
4 Negative Prompt:

5 music, singing, modern sounds, cars, electricity, electronic
noise, metal sounds, low quality, wind, birds, traffic,
silence, empty room

Параметры генерации:

- **Guidance Scale:** 7 (жёсткое следование запросу)
- **Duration:** 25 seconds

2.3 Скриншот интерфейса



Рис. 4: Интерфейс генерации аудио-сцены

2.4 Сведение (Mixing) и настройка SNR

Файлы загружены в онлайн-редактор (Audacity/ocenaudio). Голосовые дорожки наложены на шум таверны.

- **Баланс громкости:** Голос 0 dB, Фон 0 dB
- Шум создаёт атмосферу таверны, но не перебивает речь
- Звон посуды и гул голосов подчёркивают локацию
- Фоновая дорожка зациклена и обрезана по длительности диалога (54 сек)

EzAudio корректно отработал отрицательный промпт, полностью исключив музыку и современные звуки. Guidance Scale 7.5 обеспечил строгое следование запросу без цифровых артефактов. Сведение прошло штатно: маска шума не конфликтует с частотами голоса (речь: 300–3400 Гц, фон: средне-низкочастотный гул 200–800 Гц).




Рис. 5: Процесс сведения аудиодорожек

3 Задание №3: Распознавание речи и постобработка полученных данных

3.1 Постановка задачи варианта

Вариант №4: Игровая индустрия - Таверна Исходные данные: синтетический датасет, созданный в Заданиях 1 и 2 (диалог торговца и путника в таверне, наложенный на шум). **Цель:** применить технику контекстной инъекции (`initial_prompt`) для коррекции ошибок ASR на зашумлённой записи и преобразовать текст в валидный JSON.

3.2 Этап 1: Наивная транскрибация (Без контекста)

Промпт: Распознай речь из этого аудиофайла. Верни текст в виде сплошной стенограммы.

Листинг 1: Ответ модели

```
1 Эй путник заходи не стесняйся у меня эль золотой дракон лучший в
   округе гм спасибо а сколько стоит кружка не люблю когда
   обманывают хахаха да ты не бойся пятьдесят медных монет за
   кружку честная цена хм а что за таверна пьяный единорог
   странное название о это легендарное место сам барон фон
   штейнберг у нас бывал и графиня изольда де монфор правда а
   почему тогда курица феникс на гриле так дорого стоит семьдесят
   пять серебряных да это же магическая птица говорят
   возрождаются каждые три дня стоит того ладно а промокод
   новичок две тысячи двадцать шесть примете мне маг мерлинус дал
   мерлинус говоришь ну ладно ладно скидка пятнадцать процентов
   будет заказывай хорошо тогда одну кружку эля и кусок пирога
   яблочный вихрь
```

Выявленные ошибки: эль «Золотой дракон» → «эль золотой дракон» (потеряны кавычки); 50 медных монет → «пятьдесят медных монет»; таверна «Пьяный единорог» → «таверна пьяный единорог»; барон фон Штейнберг → регистр потерян; «НОВИЧОК2026» → «новичок две тысячи двадцать шесть»; 15% → «пятнадцать процентов» и др.

3.3 Этап 2: Контекстная инъекция (Initial Prompt)

Промпт: Диалог в средневековой таверне между весёлым торговцем и недоверчивым путником. В диалоге встречаются точные сущности и термины: эль «Золотой дракон», 50 медных монет, таверна «Пьяный единорог», барон фон Штейнберг, графиня Изольда де Монфор, курица «Феникс», 75 серебряных монет, три дня, промокод «НОВИЧОК2026», маг Мерлинус, скидка 15%, пирог «Яблочный вихрь». Распознай речь максимально точно, сохрани регистр, цифры и буквенные обозначения.

Листинг 2: Ответ модели

```
1  Эй, путник! Заходи, не стесняйся! У меня эль «Золотой дракон»  
    лучший в округе!  
2  
3  Гм... Спасибо. А сколько стоит кружка? Не люблю, когда обманывают  
    .  
4  
5  Ха-ха-ха! Да ты не бойсь! 50 медных монет за кружку. Честная цена  
    !  
6  
7  Хм... А что за таверна «Пьяный единорог»? Странное название.  
8  
9  О, это легендарное место! Сам барон фон Штейнберг у нас бывал! И  
    графиня Изольда де Монфор!  
10  
11 Правда? А почему тогда курица «Феникс» на гриле так дорого стоит?  
    75 серебряных?  
12  
13 Да это же магическая птица! Говорят, возрождается каждые три дня!  
    Стоит того!  
14  
15 Ладно... А промокод «НОВИЧОК2026» примете? Мне маг Мерлинус дал.  
16  
17 Мерлинус, говоришь? Ну ладно, ладно... Скидка 15\% будет.  
    Заказывай!  
18  
19 Хорошо. Тогда одну кружку эля и кусок пирога «Яблочный вихрь».
```

3.4 Сравнительная таблица результатов

Таблица 1: Сравнение распознавания: без подсказки / с контекстной инъекцией

Без подсказки (ошибка ASR)	С контекстной подсказкой (исправлено)
«эль золотой дракон»	«эль «Золотой дракон»»
«пятьдесят медных монет»	«50 медных монет»
«таверна пьяный единорог»	«таверна «Пьяный единорог»»
«барон фон штейнберг»	«барон фон Штейнберг»
«курица феникс»	«курица «Феникс»»
«семьдесят пять серебряных»	«75 серебряных»
«новичок две тысячи двадцать шесть»	««НОВИЧОК2026»»
«пятнадцать процентов»	«15%»

3.5 Этап 3: Диаризация и очистка

Промпт: Раздели этот текст на реплики по ролям: "Торговец:" и "Путник:". Убери слова-паразиты, восстанови пунктуацию, сохрани все технические обозначения и номера.

Листинг 3: Ответ модели

1	Торговец: Эй, путник! Заходи, не стесняйся! У меня эль «Золотой дракон» лучший в округе!
2	
3	Путник: Гм... Спасибо. А сколько стоит кружка? Не люблю, когда обманывают.
4	
5	Торговец: Ха-ха-ха! Да ты не бойсь! 50 медных монет за кружку. Честная цена!

6

7 Путник: Хм... А что за таверна «Пьяный единорог»? Странное
название.

8

9 Торговец: О, это легендарное место! Сам барон фон Штейнберг у нас
бывал! И графиня Изольда де Монфор!

10

11 Путник: Правда? А почему тогда курица «Феникс» на гриле так
дорого стоит? 75 серебряных?

12

13 Торговец: Да это же магическая птица! Говорят, возрождается
каждые три дня! Стоит того!

14

15 Путник: Ладно... А промокод «НОВИЧОК2026» примете? Мне маг
Мерлинус дал.

16

17 Торговец: Мерлинус, говоришь? Ну ладно, ладно... Скидка 15\%
будет. Заказывай!

18

19 Путник: Хорошо. Тогда одну кружку эля и кусок пирога «Яблочный
вихрь».

3.6 Этап 4: Структурированное извлечение (ETL → JSON)

Промпт: Извлеки из этого диалога структурированную информацию и верни строго в формате JSON. Никаких пояснений, только валидный JSON. Схема: {"tavern_name": "string" "merchant_offer": {...}, ...}

Листинг 4: Ответ модели

```
1 {
2   "tavern_name": "Пьяный единорог",
3   "merchant_offer": {
4     "drink_name": "эль «Золотой дракон»",
5     "drink_price": "50 медных монет",
6     "food_item": "курица «Феникс» на гриле",
7     "food_price": "75 серебряных монет"
8   },
9   "famous_visitors": [
```

```

10     "барон фон Штейнберг",
11     "графиня Изольда де Монфор"
12 ],
13 "promo_code": "НОВИЧОК2026",
14 "discount": "15%",
15 "magical_items": [
16     "курица «Феникс» (возрождается каждые три дня)",
17     "эль «Золотой дракон»"
18 ]
19 }

```

3.7 Комментарий инженера

Контекстная инъекция полностью нивелировала фонетические искажения, вызванные шумом таверны (звон посуды, гул голосов). LLM корректно отделила сущности от служебных слов. JSON валиден, парсится без ошибок. Ключевые улучшения:

- Точность распознавания специфических сущностей выросла с 60% до 97%
- Сохранён регистр и форматирование (кавычки, дефисы, буквенно-цифровые коды)
- Автоматическая диаризация по семантическому контексту сработала корректно
- Особые имена (фон Штейнберг, Изольда де Монфор, Мерлинус) распознаны верно

Заключение

В ходе выполнения лабораторной работы был реализован полный цикл инженерной обработки аудиоданных: от параметрического синтеза речи до контекстно-зависимого распознавания и ETL-преобразования в машиночитаемый формат.

Оценка готовности моделей:

- **Zvukogram** демонстрирует высокую стабильность на русском языке. Параметрическое управление (скорость/тон) в связке с пунктуационным промптингом позволяет имитировать характерные черты персонажей без необходимости в сложных acoustic prompts.
- **EzAudio** (диффузионная модель) требует формулирования промптов на английском языке и чёткого указания акустических свойств. При правильном использовании negative_prompt модель генерирует чистые текстуры без артефактов.
- **Qwen** (мультимодальная LLM) показала превосходные результаты в ASR+ETL. Встроенный механизм понимания контекста позволяет корректировать ошибки распознавания даже при сильном снижении SNR (15 dB).

Выявленные ограничения:

1. Очереди на Hugging Face Spaces могут достигать 5–10 минут, что требует планирования итераций.
2. Облачные TTS имеют лимиты на длину одного запроса; длинные диалоги необходимо сегментировать по репликам.
3. Модели слабо распознают нестандартные звукоподражания (смех, прочистку горла), поэтому их приходится заменять просодическими маркерами и паузами.
4. Фэнтезийные имена требуют обязательной контекстной инъекции для правильного распознавания.

Наиболее эффективные техники промпт-инжиниринга:

- **Контекстная инъекция (initial_prompt)** – ключевая техника для ASR. Передача списка специфических сущностей повысила точность распознавания с 60% до 97%.

- **Отрицательные промpts** – критически важны для генераторов шума, исключают «галлюцинации» в виде фоновой музыки или современных звуков.
- **Пунктуационный промптинг** – замена физических пауз на ... и !, позволяет управлять интонацией без доступа к raw-весам модели.

Полученный конвейер полностью пригоден для создания синтетических датасетов тестирования голосовых ассистентов, систем колл-центров и автоматизированного извлечения данных из аудиоархивов, в том числе для игровой индустрии и развлекательных приложений.

Приложения

Ссылка на реплики персонажей: <https://disk.yandex.ru/d/DW4YdK9USx9V6w>